



GPT-3: Language Models are Few-Shot Learners

📅 기간	@05/21/2025 → 05/27/2025
🕒 주차	12주차
📎 논문	https://arxiv.org/pdf/2005.14165
☀️ 상태	완료
☑️ 연습/복습	예습과제
☰ 참고 자료	참고 블로그1

0. Abstract

1. Introduction

논문이 다루는 분야
해당 task에서 기존 연구 한계점
논문의 contributions

2. Related Work

스케일과 성능에 관한 연구
작은 모델로 성능 유지 연구
더 어려운 벤치마크를 향한 도전
질의응답 및 메타러닝 관련 연구
다른 접근 방식

3. 제안 방법론(Approach)

Model and Architecture

4. 실험 및 결과

Training Dataset
Training Process
Evaluation
Results
주요 작업별 성능 예시 (few-shot 기준)
GPT-3 과제별 성능 정리표 (Few-shot 기준 중심)

5. 결론 (배운점)

Limitations
Conclusion

0. Abstract

- 1,750억 개의 파라미터를 가진 언어 모델 **GPT-3** 소개
 - 기존의 non-sparse 언어 모델보다 10배 이상 큼.
 - 주요 목표 : **모델의 크기를 단순히 키우는 것만으로도 학습 방법과 성능에 질적인 변화** 불러올 수 있는지 알아보는 것.
- GPT-3 → **파인튜닝 없이 few-shot 학습만으로도 여러 NLP 작업에서 강력한 성능** 발휘
 - 어떤 경우에는 기존 최고 성능(fine-tuned) 모델들과 비슷하거나 더 나은 성과 보여 줌.
 - 뉴스 기사처럼 사람이 작성한 것과 거의 구분 불가능한 고품질의 텍스트 생성 가능함.
- 한계 : 여전히 비논리적이거나 부정확한 응답할 수 있음.
 - 추론 능력, commonsense reasoning, 기호 조작 등에서 약점.

1. Introduction

논문이 다루는 분야


- 수년 간 자연어 처리(NLP)에서 사전학습된 언어 표현(pre-trained language representations) 사용하는 경향 두드러짐.
 - 점차적으로 더 유연하고 작업 특화되지 않은 방식으로 downstream transfer 활용

해당 task에서 기존 연구 한계점

- 초창기
 - 단일 층 표현(single-layer representations)이 단어 벡터 통해 학습
 - 작업(task) 특화된 아키텍처에 입력
- 이후
 - 여러 층의 표현과 문맥 정보 갖춘 RNN 사용
 - 더 강력한 표현 가능, 여전히 작업(task) 특화된 구조에 적용

- 최근
 - 사전학습된 순환신경망이나 트랜스포머(transformer) 언어 모델들이 직접 파인튜닝됨.
 - 작업 특화된 구조 자체가 필요 없어짐.
 - 독해, 질의응답, 텍스트 합성 등 많은 도전적인 NLP 과제에서 상당한 진전 이끔.
 - 한계점
 - 아키텍처 자체는 task-agnostic이더라도, **특정 작업에 대한 데이터셋과 파인튜닝은 여전히 필요함.**
 - 원하는 작업에서 좋은 성능을 얻기 위해서는 해당 작업에 특화된 수천~수십만 개의 예제 포함된 데이터셋 이용하여 fine-tuning 수행해야 함.
1. 새로운 작업마다 라벨 붙은 대규모 데이터셋을 요구한다는 점 → **언어 모델 활용 가능성 제한**
 - 유용할 수 있는 언어 작업의 범위 매우 넓음.
 - 문법 수정부터 추상 개념에 대한 예시 생성, 단편 소설 비평 등
 - 이러한 많은 작업에서는 대규모 지도 학습 데이터셋 수집하는 것 어렵고, 특히 작업 반복되어야 한다면 더욱 어려움.
 2. 모델의 표현력 커지고 학습 데이터 분포가 좁아질수록, 모델이 학습 데이터의 **우연한 상관관계** 이용할 가능성 높아짐. (일반화 능력 상실)
 - 사전학습+파인튜닝 패러다임에 문제 일으킬 수 있음.
 - 일반화가 실제로는 학습 데이터에 과도하게 특화, 분포 밖에서는 일반화 잘 되지 않을 수도 있음.(과적합)
 - 특정 벤치마크에서 fine-tuned 모델이 인간 수준의 성능 보여도, 그것이 실제로 과업에 대한 성능 과장할 수 있음.
 3. 인간은 대부분의 언어 작업 배우기 위해 **대규모 지도 데이터셋이 필요하지 않음.**
 - 자연어로 된 간단한 지시(ex. "이 문장이 행복한 상황인지 슬픈 상황인지 말해줘"), 아주 소수의 예시(ex. "이건 용감한 행동의 예야. 너도 용감함의 예를 하나 말해줘")

논문의 contributions



• 메타 학습(meta-learning)


- unsupervised pre-training 중, 언어 모델은 다양한 기술과 패턴 인식 능력 발전, 이후 추론 단계에서 이 능력들을 사용하여 새로운 작업에 빠르게 적응하거나 이를 인식함. ⇒ **'in-context learning'**

- 각 시퀀스의 forward-pass 중 내부 루프(inner loop) 형태로 이루어짐.

• GPT-3 훈련시켜, 이 모델이 in-context 학습 수행할 수 있는지 가설 검증

- 구체적으로 GPT-3라는 1,750억 개의 파라미터를 가진 autoregressive 언어 모델을 학습시켜, 이를 20개가 넘는 NLP 데이터셋 및 훈련 데이터에 직접 포함되어 있지 않을 가능성이 높은 몇 가지 새로운 과제에 대해 평가
- 3가지 조건에서 평가됨.

- **few-shot 학습:** 모델의 컨텍스트 윈도우에 들어갈 수 있는 만큼의 예시(보통 10~100개)를 제공
- **one-shot 학습:** 예시 1개만 제공
- **zero-shot 학습:** 예시는 전혀 제공하지 않고 자연어로 된 지시만 제공



- 모델 성능은 자연어 지시의 추가와 컨텍스트 내 예시 수(K)가 많아짐에 따라 향상됨.
- 모델 크기가 커질수록 few-shot 학습 성능 눈에 띄게 좋아짐.

2. Related Work

- 언어 모델에서 생성 성능 또는 작업 성능 개선을 위해 **파라미터 수나 연산량 증가시키는 다양한 연구**
 - 초기 연구: LSTM 기반 언어 모델을 10억 개 이상의 파라미터로 확장
 - 이후: 트랜스포머 모델 크기를 단순하게 키우는 방식으로 연구 진행
- 계산량 증가시키지 않고 **파라미터 수만 늘리는 방식**
 - 모델이 정보 저장할 수 있는 용량 늘리면서도 연산비용 최소화하는 데 초점.
 - 대표적: conditional computation 또는 mixture-of-experts 방법 → 1,000억 파라미터 모델 & 5,000만 파라미터 번역 모델 등 제안(forward pass 시 전체 파라미터 중 일부만 실제로 사용됨.)
- 반대로 파라미터 수 늘리지 않되, 계산량 늘리는 방식
 - adaptive computation time, universal transformer 등

⇒ 본 논문은 첫 번째 접근법, 즉 **계산량과 파라미터 동시에 늘리는 방식**에 기반, 기존 유사 접근법보다 **모델 크기 10배 더 키움**.

스케일과 성능에 관한 연구

- 언어 모델의 성능이 모델 크기(파라미터 수)에 따라 어떻게 변화하는지 **체계적으로 분석**
 - **loss가 모델 크기 증가에 따라 부드러운 power-law 곡선을 따른다**는 것을 확인.
 - 본 논문도 대부분의 다운스트림 작업에서 유사한 경향을 발견.

작은 모델로 성능 유지 연구

- 반대 방향의 연구로는, **가능한 한 작은 모델에서 강력한 성능을 유지하는 방법**
 - ALBERT, distillation 기반 방법 등
 - 이러한 구조와 기법은 우리 연구와 **상호보완적으로 작동**할 수 있으며, 거대 모델의 **지연시간과 메모리 사용량 감소**에 활용될 수 있음.

더 어려운 벤치마크를 향한 도전

- 파인튜닝 언어 모델이 점점 인간 성능에 가까워짐에 따라, **보다 어려운 과제들을** 만들기 위한 시도들
 - **질의응답**
 - **독해**
 - **적대적(adversarial) 데이터셋**

⇒ 우리 연구에서는 이러한 데이터셋들을 이용해 GPT-3를 평가함.

질의응답 및 메타러닝 관련 연구

- 특히 많은 선행 연구들이 **질의응답(task)**에 집중해 왔음.
 - 10억 파라미터 모델을 파인튜닝
 - 테스트 시 대규모 말뭉치를 참조하는 방식으로 접근
- 우리의 방식은 이들과 달리 **in-context 학습**에 초점을 두며, 향후에는 이들과의 **결합도 가능**
 - 메타러닝이 언급된 바 있지만, 체계적 탐구 아니었음.
 - 일반적인 메타러닝과 마찬가지로, 언어 모델 메타러닝도 **inner loop(활성화 계산)**와 **outer loop(가중치 업데이트)** 구조를 가짐.

⇒ 우리의 접근(모델 컨텍스트에 예시들을 집어넣는 방식): 가중치를 업데이트하지 않고 시간에 따른 활성화 계산을 통해 내부 적응을 수행하는 방식

다른 접근 방식

- 사전학습된 언어 모델과 **경사하강법을 결합한 few-shot 학습**
- **준지도학습(semi-supervised learning)** 접근
- **자연어로 과제를 설명하는 방식**: supervised 기반, Text-to-Text Transformer
- **다중 작업 학습(multi-task learning)**: 여러 작업을 혼합해 파인튜닝

⇒ 이러한 방식들은 **가중치 업데이트 없이 다중 작업 수행** 또는 **적은 데이터로 효과적인 학습**이라는 면에서 본 연구와 목표를 공유

3. 제안 방법론(Approach)

1. In Context Learning

- 사전 학습된 모델로 새로운 문제 풀 때 예시들을 같이 제공해주는 방법.

2. Model Capacity 늘리기

- 모델 사이즈 키우기 ⇒ 더 많은 파라미터, 더 많은 연산 수행 ⇒ 더 복잡한 데이터 분포 학습 가능

- 제안 방법

The three settings we explore for in-context learning

Zero-shot

The model predicts the answer given only a natural language description of the task. No gradient updates are performed.



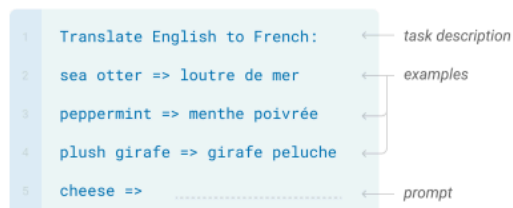
One-shot

In addition to the task description, the model sees a single example of the task. No gradient updates are performed.



Few-shot


In addition to the task description, the model sees a few examples of the task. No gradient updates are performed.



Traditional fine-tuning (not used for GPT-3)

Fine-tuning

The model is trained via repeated gradient updates using a large corpus of example tasks.



1. Zero Shot

- 모델에게 문제만 설명해주고 예시는 제공하지 않음.

2. One shot

- 모델에게 문제 설명해주고, 하나의 예시 추가 제공.

3. Few-Shot

- 모델에게 문제 설명해주고, 여러 개의 예시 추가 제공.
- GPT-3에서 가장 주요하게 사용하는 방법 (보통 10-100개의 예시 제공받아 실험 진행함.)

Model and Architecture

Model Name	n_{params}	n_{layers}	d_{model}	n_{heads}	d_{head}	Batch Size	Learning Rate
GPT-3 Small	125M	12	768	12	64	0.5M	6.0×10^{-4}
GPT-3 Medium	350M	24	1024	16	64	0.5M	3.0×10^{-4}
GPT-3 Large	760M	24	1536	16	96	0.5M	2.5×10^{-4}
GPT-3 XL	1.3B	24	2048	24	128	1M	2.0×10^{-4}
GPT-3 2.7B	2.7B	32	2560	32	80	1M	1.6×10^{-4}
GPT-3 6.7B	6.7B	32	4096	32	128	2M	1.2×10^{-4}
GPT-3 13B	13.0B	40	5140	40	128	2M	1.0×10^{-4}
GPT-3 175B or "GPT-3"	175.0B	96	12288	96	128	3.2M	0.6×10^{-4}

- GPT-2와 거의 동일한 구조를 사용
- 모델 사이즈에 대한 비교 실험을 하기 위해 다양한 사이즈 모델 제작
 - 가장 큰 모델 175B 모델을 대표 모델로 GPT-3라고 부름.

4. 실험 및 결과

Training Dataset

Dataset	Quantity (tokens)	Weight in training mix	Epochs elapsed when training for 300B tokens
Common Crawl (filtered)	410 billion	60%	0.44
WebText2	19 billion	22%	2.9
Books1	12 billion	8%	1.9
Books2	55 billion	8%	0.43
Wikipedia	3 billion	3%	3.4

- 4가지 종류의 데이터셋 사용
 1. **Common Crawl** : 웹 전체를 정기적으로 크롤링해 공개하는 대규모 데이터셋, 수십억 개의 웹페이지 포함.
 - 블로그, 뉴스, 포럼, 위키, 기술 문서 등 다양한 웹사이트 콘텐츠 포함.
 2. **WebText** : OpenAI가 GPT-2 훈련을 위해 수집한 텍스트 데이터셋으로, Reddit에서 "3개 이상의 업보트"를 받은 링크들의 콘텐츠를 수집한 웹 문서 모음
 3. **Books1, Books2** : 프로젝트 구텐베르크(Project Gutenberg)와 유사한 전자책 기반의 데이터셋으로, 수십만 권 이상의 디지털 서적을 포함.
 - **Books1** : 퍼블릭 도메인(public domain) 전자책 중심 (예: 고전 문학, 공공 텍스트)

- **Books2** : 퍼블릭 도메인이 아닐 수 있는 보다 **현대적이고 상업적인 서적**을 포함한 사실 코퍼스 (정확한 소스는 공개되지 않음)

4. **Wikipedia** : 위키백과의 기사 포함

⇒ 크게 보면 인터넷, 책, 백과사전 데이터로 학습. 데이터 수량을 기준으로 봤을 때 인터넷 데이터가 82%로 절대 다수!

Training Process

- **모델 구조** : GPT-3는 기존 GPT-2와 같은 autoregressive Transformer 아키텍처를 사용
- **크기 구성** : 총 8개의 모델 크기를 실험하였으며, 가장 큰 모델은 **1,750억 개의 파라미터**를 가짐.
- **파라미터 범위** : 1.25억 → 3.55억 → 7.74억 → 13억 → 26억 → 65억 → 130억 → 1,750억
- **학습 데이터 총량**
 - 약 3000억 토큰(token) 이상 사용
 - 대부분 **Common Crawl** 기반이며, WebText, Books1/2, Wikipedia 등이 포함됨
- **훈련 방식**
 - 단일 epoch 학습 (한 번만 전체 데이터 통과)
 - 비지도 학습 (unsupervised): 다음 단어 예측 방식
 - 토큰화 : Byte-Pair Encoding 사용

Evaluation

- **목표**: 파인튜닝 없이 **in-context learning** 능력 평가
- **3가지 설정**
 - **Zero-shot** : 지시(prompt)만 제공
 - **One-shot** : 지시 + 예시 1개
 - **Few-shot** : 지시 + 여러 예시(보통 10~32개)
- **평가 작업(Task)**
 - 언어이해 : SuperGLUE, LAMBADA
 - 질의응답 : TriviaQA, WebQuestions, NaturalQuestions, CoQA

- 번역 : WMT 2014 (EN→FR/DE), WMT 2015 (EN→RO)
- 상식추론 : HellaSwag, Winograd
- 산술 : 2~3자리 숫자 연산 문제 등
- 기타 : 단어 재배열, 소설 스타일 생성, 문장 유사도 판단

Results

- 사전학습 모델의 일반화 성능을 평가하는 것이 주 목적
- 모델 크기가 커질수록 전반적인 성능이 향상됨.

주요 작업별 성능 예시 (few-shot 기준)

과제	GPT-3 (few-shot)	기존 최고 성능 모델
CoQA	85.0 F1	90.7 F1 (fine-tuned)
TriviaQA	71.2 정확도	79.1 (fine-tuned)
LAMBADA	76.2 정확도	68.0 (GPT-2)
WMT-14 EN→FR	40.6 BLEU	41.5 (SOTA)
Arithmetic (2-digit)	98% 정확도	–

- **LAMBADA** (문맥 이해) : GPT-3의 성능이 GPT-2보다 **8.2%p 향상**
- **산술 문제** : 모델 크기가 클수록 연산 정확도가 선형적으로 증가
- **Few-shot 조건에서의 SuperGLUE 점수**: 71.8 (GPT-3), fine-tuned 모델에는 못 미치지만 remarkable

GPT-3 과제별 성능 정리표 (Few-shot 기준 중심)

 과제 유형	 데이터셋 / 벤치마크	GPT-3 성능 (Few-shot 기준)	기존 최고 성능 (비교 대상)	비고
 언어 이해	LAMBADA	76.2% (정확도)	GPT-2: 68.0%	문맥 기반 단어 예측
 상식 추론	HellaSwag	78.1%	GPT-2: 75.4%	문맥에서 자연스러운 문장 고르기
 관계 추론	Winograd	70.2%	SuperGLUE 포함	지시어 대명사 해석
 독해	CoQA	85.0 F1	90.7 (fine-tuned BERT)	QA 문제

 질의응답	TriviaQA	71.2%	79.1 (fine-tuned T5)	지식 기반 질문
	WebQuestions	68.0%	–	
	NaturalQuestions	64.0%	–	
 번역	WMT-14 EN→FR	40.6 BLEU	41.5 (SOTA)	파인튜닝 없이
	WMT-14 EN→DE	38.9 BLEU	–	
	WMT-16 EN→RO	33.2 BLEU	–	
 산술	2자리 덧셈/곱셈	98% (2-digit), 80% (3-digit)	–	파인튜닝 없음
 문장 완성	Sentence unscrambling	High (수치 미제 공)	–	문장 배열 순서 복원
 텍스트 생성	뉴스 기사 생성	사람과 구분 어려움	–	인간 평가 기반

- GPT-3는 사전 훈련만으로도 여러 과제에서 좋은 성능을 보임 (특히 few-shot)
- 여전히 **NLI**, **논리추론**, **고난도 QA** 등에서는 fine-tuned 모델이 우세
- **모델 크기 증가 + 예시 제공 수 증가 → 성능 선형 향상**
- 파인튜닝이 아닌, **단순한 prompt 설계 및 예시 제공**만으로 상당한 범용성 확보 가능

5. 결론 (배운점)

Limitations

- **언어 이해의 깊이 부족**
 - 표면적인 패턴 인식에는 능하지만, **복잡한 추론**, **논리적 일관성**, **commonsense reasoning**에는 여전히 약점이 있음.
 - 예: NLI(Natural Language Inference), 수학적 논리, 기호 조작 등에서 실수
- **비효율적인 자원 사용**
 - 1,750억 파라미터는 학습과 추론에 **막대한 컴퓨팅 자원**, **에너지 소모**를 유발함.
 - 이는 지속 가능성과 접근성을 제한할 수 있음.
- **편향(Bias)**
 - 웹 데이터를 기반으로 학습되었기 때문에 인종, 성별, 종교 등에 대한 **사회적 편향 (social bias)**을 반영할 위험이 있음.
 - 이러한 편향은 민감한 작업에서 문제를 야기할 수 있음.

- **논리적 허점**

- 언뜻 보기엔 유창한 문장을 생성하지만, **논리적 근거 없는 주장이나 사실과 다른 내용**을 자연스럽게 말할 수 있음.
- 특히, 사실 기반 QA에서 문제

Conclusion

- **주요 성과 요약**

- GPT-3는 파인튜닝 없이 다양한 NLP 작업에서 **zero-shot, one-shot, few-shot 학습**을 통해 높은 성능을 보였음.
- 모델 크기를 키우는 것만으로도 상당한 범용성과 적응력이 가능하다는 사실을 입증함.

- **In-context learning의 가능성 제시**

- 훈련된 가중치를 변경하지 않고도, 단순히 입력(prompt)만으로 새로운 작업에 적응하는 **in-context 학습 방식**의 효용성을 보여줌.

- **범용 언어 모델의 미래 가능성**

- GPT-3는 강력한 언어 생성 능력과 다양한 작업에서의 적응력 덕분에 **범용 언어 모델 (general-purpose LM)**로 발전할 수 있는 가능성을 시사함.

- **후속 연구 방향**

- 계산 효율성 향상, 편향 감소, 추론 능력 강화 등 다양한 후속 연구가 필요함.
- 특히 **지속 가능성, 공정성, 신뢰성** 확보가 중요한 과제로 제시됨.