



[12주차] 논문리뷰

GPT3

1. Introduction

논문이 다루는 분야 / 기존 연구
해당 task에서 기존 연구 한계점
논문의 contributions

GPT3

1. Introduction



논문에서 다루고 있는 주제가 무엇인지와 해당 주제의 필요성이 무엇인가
논문에서 제안하는 방법이 기존 방법의 문제점에 대응되도록 제안 되었는가

논문이 다루는 분야 / 기존 연구

- NLP / text 생성
- NLP 분야 : pre-trained language representations를 task에 맞게 transfer
 - single-layer의 표현이 word vectors를 사용해 학습
 - 이후 계층 쌓고, contextual state(문맥정보) 활용하여 더 강력한 표현 형성
 - RNN이나 Transformer 언어모델 같은 사전학습 모델 도입, 이들을 fine-tuning
→ 작업 특화 아키텍처의 필요성 없어짐

해당 task에서 기존 연구 한계점

[한계점]

- 여전히 특정 task에서 우수한 성능을 내려면, 해당 task에 특화된 데이터셋과 fine-tuning이 필요하다는 단점이 있음.
 - 새로운 task마다 대규모의 labeled 데이터셋이 필요 → 언어모델 적용성 저하

- 훈련 데이터에 편향될 수 있음 - out-of-distribution(훈련 분포 밖 환경)에서 성능이 좋지 않을 수 있음
- 대부분의 언어 task는 대규모 지도 학습 데이터를 필요로 하지 않음. 유연성과 일반성을 갖추고 있음.

[해결 방법]

- meta-learning
 - 학습 단계에서 다양한 기술과 패턴 인식 능력을 획득, inference에서 새로운 task에 빠르게 적응하는 데 사용
 - RWC+19 연구에서 “in-context learning”라고 명명하였음.
 - 모델이 자연어 명령 또는 소수의 예시를 입력으로 받아 이후의 것을 예측하는 방식으로 수행하도록 함.
 - fine-tuning보다 성능이 훨씬 낮음.




Figure 1.1: Language model meta-learning. During unsupervised pre-training, a language model develops a broad set of skills and pattern recognition abilities. It then uses these abilities at inference time to rapidly adapt to or recognize the desired task. We use the term “in-context learning” to describe the inner loop of this process, which occurs within the forward-pass upon each sequence. The sequences in this diagram are not intended to be representative of the data a model would see during pre-training, but are intended to show that there are sometimes repeated sub-tasks embedded within a single sequence.

- figure1.1. meta-learning 및 in-context learning 예시
 - unsupervised pre-training에서 다양한 기술과 패턴 인식능력 획득
 - inference할 때, 새로운 task에 빠르게 적응
 - Outer loop : 전체 사전학습 과정 (SGD를 통한 학습)
 - Inner loop : In-context learning. 입력 시퀀스 내에서 작업 예시들을 보고 빠르게 작업을 인식

- 덧셈 문제, 철자 교정, 번역 등
- ⇒ 하나의 시퀀스 안에 있는 여러 예시들을 통해 모델이 새로운 작업을 파인튜닝 없이도 처리하는 과정
- transformer 모델 크기 증가
 - 모델의 파라미터 수는 최근 몇년 간 꾸준히 증가해왔음.
 - 이는 text 생성, NLP 작업 등에서 성능 향상을 보였음.

논문의 contributions

[GPT-3]

- GPT3: 1,750억 개의 파라미터를 가진 autogressive 언어 모델
- in-context learning 능력을 측정함
- 20개 이상의 NLP 데이터셋과 여러 새로운 테스트 작업을 통해 평가
- 훈련 중 직접 학습하지 않았을 가능성이 높은 작업에 대한 적응 능력을 평가
 - Few-shot learning : 예시 여러개 넣어서 학습시킨 후 평가
 - One-shot learning : 예시 1개
 - Zero-shot learning : 예시X

[성능]

- GPT-3는 zero-shot, one-shot, few-shot 조건 모두에서 좋은 성능 보임
- 최첨단 fine-tuned 모델을 능가하거나 근접한 성능 보이기도 함
- 단어 재배열, 산술 연산, 문장 내에서 단어의 “새로운 사용”을 요구하는 작업들에서 우수한 zero-shot 및 one-shot 성능 보임
- few-shot 설정에서 인간이 작성한 기사와 구분하기 어려운 뉴스 기사를 생성하기도 함
- ANLI와 같은 자연어 추론 과제나 RACE, QuAC 등 일부 독해 작업에서는 성능이 낮게 나오기도 했음

[Data Contamination]

- 대규모 모델 훈련 시 Common Crawl과 같은 데이터셋에서 테스트 데이터 일부가 이미 존재할 수 있어 모델 평가를 왜곡할 가능성이 있음
- 오염 측정 도구를 개발하여 GPT-3의 성능에 미치는 영향을 정량화했음
- 주석(*)을 달거나 결과를 생략하여 오염 효과 줄임

[GPT3보다 작은 모델들과 비교]

- 1.25억 ~ 130억 파라미터
- 모델 규모가 커질수록 성능이 매끄럽게 향상됨
- 특히 모델이 클수록 zero/one/few-shot 간 성능 격차도 커졌음

[기타]

- GPT3의 능력이 엄청날 걸 고려해서 편향, 공정성, 사회적 영향에 대해 논의함
- GPT3의 초기 특성에 대해 분석했음

[figure 설명]




Figure 1.2: Larger models make increasingly efficient use of in-context information. We show in-context learning performance on a simple task requiring the model to remove random symbols from a word, both with and without a natural language task description (see Sec. 3.9.2). The steeper “in-context learning curves” for large models demonstrate improved ability to learn a task from contextual information. We see qualitatively similar behavior across a wide range of tasks.

- figure 1.2. 모델 크기(파라미터수)에 따른 in-context 학습의 효율성 비교
 - 단어에서 무작위로 기호 제거하는 작업
 - 자연어 프롬프트 있을 때와 없을 때 모두 진행해서 비교
 - 큰 모델일수록 in-context 예시를 더 잘 활용
 - 자연어로 작업을 설명해주는 프롬프트가 있을 때 성능이 더 좋음

⇒ 더 큰 언어 모델일수록 "프롬프트"와 "문맥 내 예시"를 더 잘 활용하여 새로운 작업을 빠르게 학습. = 대규모 모델이 in-context learning에 더 강력함




Figure 1.3: Aggregate performance for all 42 accuracy-denominated benchmarks While zero-shot performance improves steadily with model size, few-shot performance increases more rapidly, demonstrating that larger models are more proficient at in-context learning. See Figure 3.8 for a more detailed analysis on SuperGLUE, a standard NLP benchmark suite.

- figure 1.3. 42개의 벤치마크에서 GPT 계열 모델의 평균 성능 비교
 - x축 : 모델 크기(파라미터수) / y축 : 정확도
 - zero-shot, one-shot, few-shot 성능 비교
 - 모델 크기가 커질수록 zero-shot, one-shot, few-shot 모두 성능이 향상됨
 - few-shot 학습의 성능 향상 속도가 가장 빠르게 증가함
 - 큰 모델일수록 in-context learning에서 더 큰 이점이 있음
- ⇒ 대규모 언어 모델이 일반화된 작업 수행 능력을 더 잘 갖추고 있음