



EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks

📅 기간	@06/18/2025 → 06/24/2025
📌 주차	16주차
📎 논문	https://arxiv.org/pdf/1905.11946
🌟 상태	완료
☑️ 연습/복습	예습과제
☰ 참고 자료	참고 블로그1

0. Abstract

1. Introduction

논문이 다루는 분야

해당 task에서 기존 연구 한계점

논문의 contributions

2. Related Work

3. Compound Model Scaling

3.1 Problem Formulation

3.2 Scaling Dimensions

3.3 Compound Scaling

✅ 제안하는 복합 스케일링 방법

4. EfficientNet Architecture

5. 실험 및 결과

5.1 Scaling Up MobileNets and ResNets

5.2 ImageNet Results for EfficientNet

5.3 Transfer Learning Results for EfficientNet

6. Discussion & Conclusion


⇒ 다양한 스케일링 방법 간 성능 비교

⇒ 왜 복합 스케일링이 더 나은가?

결론

0. Abstract

- 합성곱 신경망 → 일반적으로 고정된 자원 예산에 맞춰 개발되며, 추가 자원이 확보되면 더 나은 정확도를 위해 확장됨.
- 본 논문 → 모델 스케일링을 체계적으로 연구, **네트워크의 깊이(depth), 너비(width), 해상도(resolution)**를 균형 있게 조정하면 더 나은 성능 얻을 수 있다는 사실 발견.
 - 이를 바탕으로 깊이/너비/해상도의 모든 차원을 단순하면서도 효과적인 복합 계수 (compound coefficient)를 통해 균일하게 확장하는 새로운 스케일링 방법 제안함.
 - MobileNet 및 ResNet과 같은 기존 모델 확장하는 데 효과적임을 입증함.
- 신경망 구조 탐색을 활용하여 새로운 베이스라인 네트워크 설계하고, 이를 확장하여 **EfficientNet**이라는 모델 계열 개발함.
 - 기존 ConvNet보다 훨씬 뛰어난 정확도와 효율성 달성.
 - EfficientNet-B7: ImageNet에서 84.3% top-1 정확도 기록, 기존 최고 모델보다 8.4배 작고, 6.1배 빠른 추론 속도.
 - 전이 학습에도 잘 적용, CIFAR-100(91.7%), Flowers(98.8%) 및 기타 3개의 전이학습 데이터셋에서 최고 정확도를 기록
 - 파라미터 수는 기존보다 훨씬 적음.



1. Introduction

논문이 다루는 분야

- 딥러닝 기반의 이미지 분류, 특히 CNN 아키텍처 확장 및 최적화
- ConvNet 확장하는 과정 → 체계적으로 연구된 바가 거의 없음. 현재도 많은 방식들이 혼용
 - 가장 일반적인 방법: 깊이(depth) 또는 너비(width) 증가시키는 것.
 - 최근에는 입력 이미지 해상도 증가시키는 방식.

해당 task에서 기존 연구 한계점

- 기존 연구들에서는 세 차원 중 하나만 확장하는 것이 보편적.
 - 2-3개 동시에 확장하더라도 임의적이고 수동적인 튜닝이 필요함.
 - 성능 또한 최적화되지 않는 경우 많음.


논문의 contributions

- 더 나은 정확도와 효율성을 동시에 얻기 위해, ConvNet을 확장하는 정교한 방법??
 - ⇒ 네트워크의 깊이, 너비, 해상도를 균형 있게 조정하는 것이 중요
- 위 균형은 일정한 비율로 함께 확장함으로써 달성될 수 있음!!

- **compound scaling** 제안

- 기존 관행처럼 차원을 임의로 확장하는 것이 아니라, **정해진 비율의 계수로 네트워크 깊이, 너비, 해상도를 균일하게 확장!**

ex) 2^n 배의 연산 자원 → 네트워크의 깊이를 α^n , 너비를 β^n , 해상도를 γ^n 만큼 증가시킴. 여기서 α, β, γ 는 작은 모델을 기반으로 한 그리드 서치를 통해 정해지는 상수.



- 입력 이미지 커지면, 네트워크 더 많은 레이어(깊이)가 필요, 더 정밀한 패턴 인식하기 위해 더 많은 채널(너비) 필요함.
 - 이 세 차원의 상관관계는 이론적/실험적 연구에서도 입증되어 왔지만, **세 차원 모두를 정량적으로 다룬 연구는 본 논문이 처음.**
- 제안한 방법은 기존 MobileNet 및 ResNet에도 잘 적용됨을 보임.
- 더 나아가 신경망 구조 탐색(NAS) 활용하여 **EfficientNet-B0**이라는 새로운 모바일 사이즈 베이스라인 네트워크 설계.
 - 복합 스케일링 적용하여 EfficientNet-B1~B7 모델 생성

2. Related Work

- **ConvNet의 정확도 향상**

- AlexNet이 우승한 이후, ConvNet은 점차 대형화되며 정확도 높여옴.
 - GoogleNet, SENet
- 가장 최근 → GPipe: 557M 파라미터 사용하여 정확도 84.1% 기록
 - 그러나 모델이 너무 커서, 네트워크 분할하고 각 부분을 다른 가속기로 분산시켜 학습하는 파이프라인 병렬화 라이브러리 필요함.

- ImageNet에서의 성능이 다른 전이학습 데이터셋이나 객체 탐지와 같은 다양한 컴퓨터 비전 작업에서도 좋은 성능 보이는 것으로 나타남.
 - 하드웨어 메모리 한계에 이미 도달. → 향후 정확도 향상 위해서는 더 나은 효율성 요구됨.
- **ConvNet의 효율성 개선**
 - 과다한 파라미터 포함. → 모델 압축은 정확도 일부를 희생하여 모델 크기 줄이는 일반적인 접근.
 - 모바일 환경의 대중화 → 경량화된 모바일용 ConvNet 많이 개발
 - SqueezeNet, MobileNet, ShuffleNet 등
 - 최근에는 신경망 구조 탐색(NAS) 이용하여 효율적인 모바일용 ConvNet 설계하는 시도
 - 네트워크 너비, 깊이, 커널 종류 및 크기 조정하여 핸드크래프트 방식보다 뛰어난 효율 보임.
 - 하지만, 아직 대규모 모델에는 어떻게 적용될 수 있는지는 명확하지 않음.
 - 큰 모델은 설계 공간 훨씬 넓고, 튜닝 비용도 매우 크기 때문.
- ⇒ 해결책으로 모델 스케일링 채택!
- **모델 스케일링**
 - 자원 제약에 따라 ConvNet을 스케일링하는 방법
 - ResNet → 레이어 수 조정, ResNet-18 또는 ResNet-200
 - WideResNet & MobileNet → 채널 수 조정하여 너비 확장
 - 입력 이미지 크기(해상도) 커지면 정확도 향상됨.(단, 계산량은 증가함.)
 - 이전 연구들 → 네트워크의 깊이와 너비가 모델 표현력에 중요한 요소라는 것 보여 주었지만, 세 가지 차원을 어떻게 조화롭게 확장하면 정확도&효율성 동시에 얻을 수 있을지에 대한 명확한 해답 아직 없음.

3. Compound Model Scaling

3.1 Problem Formulation

- ConvNet의 Layer i 는 함수로 정의할 수 있음.

$$Y_i = F_i(X_i)$$

- F_i : 연산자(operator)
- X_i : 입력 텐서
- Y_i : 출력 텐서
- 입력 텐서 X_i 의 텐서 형태는 $\langle H_i, W_i, C_i \rangle$
- H_i, W_i : 공간 해상도(height x width)
- C_i : 채널 수
- ConvNet 전체는 여러 계층의 연산으로 구성됨.

$$N = F_k \circ \dots \circ F_2 \circ F_1(X_1) = \bigodot_{j=1}^k F_j(X_1)$$

- 실제에서는 ConvNet이 여러 스테이지로 나뉘며, 각 스테이지 안의 계층은 같은 구조를 가짐.
 - ResNet은 5개의 스테이지로 구성, 첫 계층 제외하고 각 스테이지는 같은 종류의 합성곱을 수행함.
- ConvNet 정의

$$N = \bigodot_{i=1}^s F_i^{L_i}(X^{\langle H_i, W_i, C_i \rangle})$$

- $F_i^{L_i}$: 스테이지 i에 있는 연산자 F_i 가 L_i 번 반복됨을 의미.
- $\langle H_i, W_i, C_i \rangle$: 각 계층의 입력 형태.

📌 예시: Figure 2(a)에 나온 대표적인 ConvNet은 공간 해상도는 점점 작아지고 채널 수는 점점 커집니다. 예컨대 입력은 $\langle 224, 224, 3 \rangle$ 이고 출력은 $\langle 7, 7, 512 \rangle$ 임.

기존 ConvNet 설계는 주로 F_i (계층의 구조)를 고정하고 최적 구조를 찾는 데 초점 맞춰져 있음. → 모델 스케일링은 이와 달리 계층 수(길이 L), 채널 수(C), 해상도(H, W)를 확장하면서 F_i 고정함.

⇒ 설계 공간을 줄이지만 여전히 각 계층의 L_i, C_i, H_i, W_i 조합에 대한 탐색 필요.

⇒ 해결을 위해 모든 계층을 동일한 비율로 확장한다고 가정!

< 최종 목표 → 주어진 자원 제약 하에서 정확도를 최대화하는 것 >


$$\begin{aligned}
& \max_{d,w,r} \text{Accuracy}(\mathcal{N}(d,w,r)) \\
& s.t. \quad \mathcal{N}(d,w,r) = \bigodot_{i=1 \dots s} \hat{\mathcal{F}}_i^{d \cdot \hat{L}_i}(X_{\langle r \cdot \hat{H}_i, r \cdot \hat{W}_i, w \cdot \hat{C}_i \rangle}) \\
& \quad \text{Memory}(\mathcal{N}) \leq \text{target_memory} \\
& \quad \text{FLOPS}(\mathcal{N}) \leq \text{target_flops}
\end{aligned} \tag{2}$$

3.2 Scaling Dimensions

- 식 (2)의 어려움 → 최적의 d, w, r 값이 서로 영향 주며, 자원 제약 조건에 따라 변한다는 점.
- ⇒ 기존 방식은 보통 하나의 차원만 확장함.

Depth (깊이, d)

- 가장 보편적인 스케일링 방법 (예: ResNet, Inception 등)
- 더 깊은 네트워크는 복잡한 특징을 더 잘 포착, 기울기 소실 문제와 학습 난이도 증가
- 아래 중앙 그림에서는 깊이 증가시키는 경우 정확도 향상이 포화되는 것을 보여줌.



Width (너비, w)

- MobileNet, EfficientNet 등 경량 모델에서 주로 사용됨.
- 채널 수 늘리면 정밀한 특징 더 잘 포착하고 학습이 쉬움.
- 그러나, 얇고 넓기만 한 네트워크는 고수준 특징 포착하는 데 한계
- 왼쪽 그림: 너비만 확장할 경우 빠르게 성능이 포화됨.

Resolution (해상도, r)

- 입력 이미지 해상도가 높을수록 미세한 정보를 더 잘 인식
- 초기 CNN → 224×224, 최신은 299×299, 480×480 이상 사용


- 오른쪽 그림: 해상도 높일수록 정확도가 향상되지만, 일정 수준 이후 성능 향상 제한 됨.

⇒ 관찰 1 (Observation 1)

- 네트워크의 깊이, 너비, 해상도 중 어떤 차원이든 확장하면 정확도는 향상되지만, 큰 모델에서는 정확도 향상이 점차 줄어듦.(포화 현상).

3.3 Compound Scaling

- 각 스케일링 차원은 독립적이지 않으며 상호작용함.
 - 해상도가 높아지면, 더 넓은 수용 영역 확보하기 위해 깊이 늘려야 함.
 - 더 많은 픽셀 정보 포착하기 위해 너비(채널 수)도 증가시켜야 함.



- 깊이(d) = 1.0, 해상도(r) = 1.0 상태에서는 너비 확장 효과가 빠르게 포화됨.
- 반면 $d = 2.0, r = 1.3$ 인 경우에는 동일한 FLOPS 하에서도 성능이 더 높게 나옴.

⇒ 관찰 2 (Observation 2)

- 너 나은 정확도와 효율성을 달성하기 위해서는 깊이, 너비, 해상도를 균형 있게 확장하는 것이 중요함.

✅ 제안하는 복합 스케일링 방법

- 다음과 같이, 단일 계수 ϕ 를 사용하여 세 차원을 동시에 확장함.

$$\begin{aligned}
&\text{depth: } d = \alpha^\phi \\
&\text{width: } w = \beta^\phi \\
&\text{resolution: } r = \gamma^\phi \\
&\text{s.t. } \alpha \cdot \beta^2 \cdot \gamma^2 \approx 2 \\
&\alpha \geq 1, \beta \geq 1, \gamma \geq 1
\end{aligned} \tag{3}$$

- α, β, γ : 스케일링 계수 → 작은 모델에서 그리드 서치로 한 번만 탐색
- ϕ : 사용자가 지정한 리소스 확장 정도 (예: 2배 리소스면 $\phi = 1$)
- ※ 왜 $\beta^2 \cdot \gamma^2$ 가 포함되는가?
 - 합성곱 연산의 FLOPS는 **깊이(d) $\propto$ 선형, 너비(w), 해상도(r) $\propto$ 제곱**으로 증가하기 때문.

$$FLOPS \propto (\alpha \cdot \beta^2 \cdot \gamma^2)^\phi$$

→ 계산량 증가를 제어하기 위해 제약 조건 $\alpha \cdot \beta^2 \cdot \gamma^2 \approx 2$ 설정함으로써, ϕ 당 FLOPS가 2배 증가하도록 설계함.

4. EfficientNet Architecture

- 기존 베이스라인 네트워크 계층 연산자 $\hat{F}_i$ 변경하지 않기 때문에, 우수한 베이스라인 네트워크 갖추는 것 또한 매우 중요함.
- 새로운 모바일 사이즈의 베이스라인 네트워크 → **EfficientNet-B0** 설계

EfficientNet-B0 설계

- 정확도와 FLOPS 동시에 고려하는 다중 목표 최적화 기반 신경망 구조 탐색을 사용함.
- 탐색 공간: (Tan et al., 2019)과 동일
- 최적화 목표: $ACC(m) \times \left[\frac{FLOPS(m)}{T} \right]^w$
- 여기서
 - $ACC(m)$: 모델 mmm의 정확도
 - $FLOPS(m)$: 연산량
 - T : 목표 FLOPS

- $w = -0.07$: 정확도-효율성 간의 trade-off 조절 하이퍼파라미터

Table 1. EfficientNet-B0 baseline network – Each row describes a stage i with $\hat{L}_i$ layers, with input resolution $\langle \hat{H}_i, \hat{W}_i \rangle$ and output channels $\hat{C}_i$. Notations are adopted from equation 2.

Stage i	Operator $\hat{\mathcal{F}}_i$	Resolution $\hat{H}_i \times \hat{W}_i$	#Channels $\hat{C}_i$	#Layers $\hat{L}_i$
1	Conv3x3	224×224	32	1
2	MBConv1, k3x3	112×112	16	1
3	MBConv6, k3x3	112×112	24	2
4	MBConv6, k5x5	56×56	40	2
5	MBConv6, k3x3	28×28	80	3
6	MBConv6, k5x5	14×14	112	3
7	MBConv6, k5x5	14×14	192	4
8	MBConv6, k3x3	7×7	320	1
9	Conv1x1 & Pooling & FC	7×7	1280	1

- 주 블록은 모바일 인버티드 병목 MBConv
- 여기에 Squeeze-and-Excitation(SE) 모듈도 추가 적용
⇒ 기존 MnasNet과 유사한 구조이지만 목표 FLOPS가 더 크기 때문에 약간 더 큰 네트워크임.

복합 스케일링 적용 절차

- EfficientNet-B0를 기반으로, 앞서 제안한 복합 스케일링을 두 단계로 적용하여 EfficientNet-B1~B7 모델을 만들.

STEP 1: 계수 α, β, γ 탐색

- 자원이 2배로 주어진 상황을 가정하여 $\phi = 1$ 고정
- 식 (2), (3) 기반으로 작은 범위의 그리드 서치를 수행
- 최적 결과
 - $\alpha = 1.2$ (깊이 계수)
 - $\beta = 1.1$ (너비 계수)
 - $\gamma = 1.15$ (해상도 계수)
- 제약 조건 만족 : $\alpha \cdot \beta^2 \cdot \gamma^2 \approx 2$

STEP 2: EfficientNet 확장

- 이제 α, β, γ 를 고정하고, 다양한 ϕ 값에 따라 EfficientNet-B1 ~ B7 생성
- 예:

- B1: $\phi = 1$
- B7: $\phi = 7$
- 각 차원을 $d = \alpha^\phi, w = \beta^\phi, r = \gamma^\phi$ 로 확장

⇒ 주의 : 더 큰 모델에 대해 α, β, γ 를 새로 찾으면 더 좋은 성능이 가능하겠지만, 탐색 비용이 너무 크기 때문에 소형 모델에서 한 번만 탐색하고 동일 계수를 모든 모델에 공통으로 사용함.

5. 실험 및 결과

5.1 Scaling Up MobileNets and ResNets

Table 3. Scaling Up MobileNets and ResNet.

Model	FLOPS	Top-1 Acc.
Baseline MobileNetV1 (Howard et al., 2017)	0.6B	70.6%
Scale MobileNetV1 by width ($w=2$)	2.2B	74.2%
Scale MobileNetV1 by resolution ($r=2$)	2.2B	72.7%
compound scale ($d=1.4, w=1.2, r=1.3$)	2.3B	75.6%
Baseline MobileNetV2 (Sandler et al., 2018)	0.3B	72.0%
Scale MobileNetV2 by depth ($d=4$)	1.2B	76.8%
Scale MobileNetV2 by width ($w=2$)	1.1B	76.4%
Scale MobileNetV2 by resolution ($r=2$)	1.2B	74.8%
MobileNetV2 compound scale	1.3B	77.4%
Baseline ResNet-50 (He et al., 2016)	4.1B	76.0%
Scale ResNet-50 by depth ($d=4$)	16.2B	78.1%
Scale ResNet-50 by width ($w=2$)	14.7B	77.7%
Scale ResNet-50 by resolution ($r=2$)	16.4B	77.5%
ResNet-50 compound scale	16.7B	78.8%

- MobileNet과 ResNet 같은 널리 사용되는 모델에 제안한 복합 스케일링 기법 적용.
⇒ 단일 차원 스케일링보다 복합 스케일링이 항상 더 나은 정확도 달성함.

5.2 ImageNet Results for EfficientNet

- EfficientNet 모델은 (Tan et al., 2019)과 유사한 설정으로 ImageNet에서 학습함.
 - **최적화기**: RMSProp (감쇠 계수 0.9, 모멘텀 0.9)
 - **Batch Norm** 모멘텀: 0.99
 - **가중치 감쇠**: $1e-5$
 - **초기 학습률**: 0.256 (매 2.4 epoch마다 0.97씩 감소)
 - **활성화 함수**: SiLU(Swish-1)
 - **데이터 증강**: AutoAugment

- 정규화: Stochastic depth (생존 확률 0.8), dropout은 B0 0.2에서 B7 0.5로 선형 증가
- 검증은 훈련셋에서 **25K개 이미지**를 랜덤으로 따로 분리한 **minival** 세트로 **early stopping** 진행 → 최종 결과는 original validation set에서 평가

Model	Top-1 Acc.	Top-5 Acc.	#Params	Ratio-to-EfficientNet	#FLOPs	Ratio-to-EfficientNet
EfficientNet-B0	77.1%	93.3%	5.3M	1x	0.39B	1x
ResNet-50 (He et al., 2016)	76.0%	93.0%	26M	4.9x	4.1B	11x
DenseNet-169 (Huang et al., 2017)	76.2%	93.2%	14M	2.6x	3.5B	8.9x
EfficientNet-B1	79.1%	94.4%	7.8M	1x	0.70B	1x
ResNet-152 (He et al., 2016)	77.8%	93.8%	60M	7.6x	11B	16x
DenseNet-264 (Huang et al., 2017)	77.9%	93.9%	34M	4.3x	6.0B	8.6x
Inception-v3 (Szegedy et al., 2016)	78.8%	94.4%	24M	3.0x	5.7B	8.1x
Xception (Chollet, 2017)	79.0%	94.5%	23M	3.0x	8.4B	12x
EfficientNet-B2	80.1%	94.9%	9.2M	1x	1.0B	1x
Inception-v4 (Szegedy et al., 2017)	80.0%	95.0%	48M	5.2x	13B	13x
Inception-resnet-v2 (Szegedy et al., 2017)	80.1%	95.1%	56M	6.1x	13B	13x
EfficientNet-B3	81.6%	95.7%	12M	1x	1.8B	1x
ResNeXt-101 (Xie et al., 2017)	80.9%	95.6%	84M	7.0x	32B	18x
PolyNet (Zhang et al., 2017)	81.3%	95.8%	92M	7.7x	35B	19x
EfficientNet-B4	82.9%	96.4%	19M	1x	4.2B	1x
SENet (Hu et al., 2018)	82.7%	96.2%	146M	7.7x	42B	10x
NASNet-A (Zoph et al., 2018)	82.7%	96.2%	89M	4.7x	24B	5.7x
AmoebaNet-A (Real et al., 2019)	82.8%	96.1%	87M	4.6x	23B	5.5x
PNASNet (Liu et al., 2018)	82.9%	96.2%	86M	4.5x	23B	6.0x
EfficientNet-B5	83.6%	96.7%	30M	1x	9.9B	1x
AmoebaNet-C (Cubuk et al., 2019)	83.5%	96.5%	155M	5.2x	41B	4.1x
EfficientNet-B6	84.0%	96.8%	43M	1x	19B	1x
EfficientNet-B7	84.3%	97.0%	66M	1x	37B	1x
GPipe (Huang et al., 2018)	84.3%	97.0%	557M	8.4x	-	-

We omit ensemble and multi-crop models (Hu et al., 2018), or models pretrained on 3.5B Instagram images (Mahajan et al., 2018).

- EfficientNet-B7은 **GPipe**와 정확도는 동일하지만, **파라미터 수는 8.4배 작고, FLOPS는 훨씬 적음.**
- B3는 **ResNeXt-101**보다 높은 정확도를 **18배 적은 연산량**으로 달성.

5.3 Transfer Learning Results for EfficientNet

Table 5. EfficientNet Performance Results on Transfer Learning Datasets. Our scaled EfficientNet models achieve new state-of-the-art accuracy for 5 out of 8 datasets, with 9.6x fewer parameters on average.


	Comparison to best public-available results						Comparison to best reported results					
	Model	Acc.	#Param	Our Model	Acc.	#Param(ratio)	Model	Acc.	#Param	Our Model	Acc.	#Param(ratio)
CIFAR-10	NASNet-A	98.0%	85M	EfficientNet-B0	98.1%	4M (21x)	¹ Gpipe	99.0%	556M	EfficientNet-B7	98.9%	64M (8.7x)
CIFAR-100	NASNet-A	87.5%	85M	EfficientNet-B0	88.1%	4M (21x)	Gpipe	91.3%	556M	EfficientNet-B7	91.7%	64M (8.7x)
Birdsnap	Inception-v4	81.8%	41M	EfficientNet-B5	82.0%	28M (1.5x)	GPipe	83.6%	556M	EfficientNet-B7	84.3%	64M (8.7x)
Stanford Cars	Inception-v4	93.4%	41M	EfficientNet-B3	93.6%	10M (4.1x)	[‡] DAT	94.8%	-	EfficientNet-B7	94.7%	-
Flowers	Inception-v4	98.5%	41M	EfficientNet-B5	98.5%	28M (1.5x)	DAT	97.7%	-	EfficientNet-B7	98.8%	-
FGVC Aircraft	Inception-v4	90.9%	41M	EfficientNet-B3	90.7%	10M (4.1x)	DAT	92.9%	-	EfficientNet-B7	92.9%	-
Oxford-IIIT Pets	ResNet-152	94.5%	58M	EfficientNet-B4	94.8%	17M (5.6x)	GPipe	95.9%	556M	EfficientNet-B6	95.4%	41M (14x)
Food-101	Inception-v4	90.8%	41M	EfficientNet-B4	91.5%	17M (2.4x)	GPipe	93.0%	556M	EfficientNet-B7	93.0%	64M (8.7x)
Geo-Mean						(4.7x)						(9.6x)

¹GPipe (Huang et al., 2018) trains giant models with specialized pipeline parallelism library.

[‡]DAT denotes domain adaptive transfer learning (Ngiam et al., 2018). Here we only compare ImageNet-based transfer learning results.

Transfer accuracy and #params for NASNet (Zoph et al., 2018), Inception-v4 (Szegedy et al., 2017), ResNet-152 (He et al., 2016) are from (Kornblith et al., 2019).

- GPipe와 비교해도 EfficientNet은 5개 데이터셋에서 더 나은 정확도를 보이며, 평균 **9.6배 파라미터 절감**



- EfficientNet은 다양한 모델 대비 압도적인 효율성과 정확도 보여줌.

6. Discussion & Conclusion

- 제안한 복합 스케일링(compound scaling) 기법이 실제로 정확도 향상에 얼마나 기여했는지 이해하고자, EfficientNet-B0 기준으로 다양한 스케일링 방법들을 비교 분석함.

⇒ 다양한 스케일링 방법 간 성능 비교

Figure 8은 동일한 EfficientNet-B0 베이스라인을 출발점으로 하여, **깊이만, 너비만, 해상도만, 복합적으로** 각각 확장했을 때 ImageNet Top-1 정확도가 어떻게 변화하는지를 보여줌.




Figure 8. Scaling Up EfficientNet-B0 with Different Methods.

- 모든 스케일링 방식은 FLOPS 증가에 따라 정확도가 향상됨
 - 하지만 **복합 스케일링 방식**은 단일 차원 확장보다 최대 **2.5% 더 높은 정확도**를 달성
 - 이는 복합 스케일링의 **정확도 개선 기여도가 매우 크다는 점**을 강조함

⇒ 왜 복합 스케일링이 더 나은가?

Class Activation Map (CAM) 시각화를 통해, 복합 스케일링이 왜 더 뛰어난지를 정성적으로 분석함.




Figure 7. **Class Activation Map (CAM)** (Zhou et al., 2016) for Models with different scaling methods- Our compound scaling method allows the scaled model (last column) to focus on more relevant regions with more object details. Model details are in Table 7.

Table 7. **Scaled Models Used in Figure 7.**

Model	FLOPS	Top-1 Acc.
Baseline model (EfficientNet-B0)	0.4B	77.3%
Scale model by depth ($d=4$)	1.8B	79.0%
Scale model by width ($w=2$)	1.8B	78.9%
Scale model by resolution ($r=2$)	1.9B	79.1%
Compound Scale ($d=1.4, w=1.2, r=1.3$)	1.8B	81.1%

- 예시 이미지: ImageNet 검증 세트에서 무작위로 추출
- 비교 대상: EfficientNet-B0을 기반으로 각각
 - 깊이만 4배 확장 ($d=4$)
 - 너비만 2배 확장 ($w=2$)
 - 해상도만 2배 확장 ($r=2$)
 - 복합 스케일링 ($d=1.4, w=1.2, r=1.3$)

✓ 관찰 결과:

- 단일 확장 모델은 객체의 일부만 강조하거나, 세부 정보를 놓치는 경향

- 반면 **복합 스케일링 모델**은 전체 객체를 정확히 감지하고 세부 정보까지 포착
 - 즉, 더 넓은 수용 영역(**receptive field**) + 더 많은 채널 수 + 고해상도 입력이 시너지 효과를 냄.
-

결론

- 본 논문에서 우리는 ConvNet을 스케일링할 때 단일 차원이 아닌, **깊이, 너비, 해상도 세 차원을 균형 있게 확장하는 것**이 중요하다는 점을 실증적으로 밝혔음.
- 이를 해결하기 위해 단순하지만 강력한 방법인 **복합 스케일링(compound scaling)**을 제안!
- 이 방법은 주어진 자원 제약 내에서 **정확도를 최대화하고 효율성도 유지 가능하게 해 줌**.
- EfficientNet은 이 스케일링 전략을 활용하여 **모바일 사이즈의 작은 모델에서부터 대규모 모델까지 일관되게 고성능을 달성**
- 결과적으로 EfficientNet은 ImageNet 및 다양한 전이학습 과제에서 SOTA 달성했으며, **연산량과 파라미터 수는 기존보다 한 자릿수 이상 줄임**.